

지하철 혼잡도 예측 및 추천 시스템 구축

데이터마이닝 (나)반

20210365 이예찬

20201349 이선표

본 논문은 지하철 이용자들의 효율적인 이동을 지원하기 위해 시간대별 혼잡도를 예측하고, 혼잡도가 낮은 시간대를 추천하는 시스템을 구축하는 것을 목표로 한다. 이를 위해 서울시 지하철 7호선을 중심으로 과거의 혼잡도 데이터를 수집하고, 다양한 시간 인코딩 방식과 머신러닝 모델을 비교하였다. 특히 선형 회귀와 XGBoost 모델을 중심으로 성능을 비교하고, 최적의 모델을 바탕으로 사용자 맞춤형 추천 시스템을 구현하였다. 본 연구는 대중교통의 효율성과 교통약자 보호 측면에서도 사회적 의의를 갖는다.

1. 서론

도시의 교통체계는 단순한 이동수단의 집합을 넘어, 시민들의 일상생활, 경제활동, 사회적 관계 형성에 이르기까지 도시 생활 전반에 깊이 관여하는 핵심 인프라이다. 그 중에서도 대중교통, 특히 지하철 시스템은 대도시에서 필수불가결한 이동 수단으로 기능하고 있으며, 서울과 같은 초고밀도 도시에서는 하루 수백만 명에 이르는 이용자가 지하철을 통해 이동하고 있다. 그러나 대중교통의 효율성은 그 시스템의 접근성, 정시성, 연결성뿐만 아니라 혼잡도에 의해서도 크게 좌우된다.

서울의 경우, 출퇴근 시간대에 발생하는 지하철 혼잡도는 국제적으로도 높은 수준으로 보고되고 있으며, 이는 이용자들의 삶의 질에 직결되는 중요한 문제이다. 혼잡한 환경에서의 통근은 단순히 물리적인 불편을 넘어, 심리적 스트레스, 신체 피로도 증가, 건강 악화 등의 부정적 영향을 유발할 수 있으며, 장기적으로는 생산성 저하나 직무 만족도 감소 등 사회경제적 손실로 이어질 수 있다. 더욱이, 과도한 혼잡은 승객 간 충돌, 기기 고장, 응급 상황 대처 지연 등 안전사고의 원인으로도 작용할 수 있다.

이러한 문제는 사회적 약자, 예컨대 노약자, 임산부, 어린이, 휠체어 이용자 등에게 더욱 심각한 위협으로 작용한다. 이들은 일반 승객보다 공간 확보가 필요하거나, 일정한 속도 이상으로 움직이기 어렵기 때문에 혼잡한 대중교통 환경에서 배제되거나 위협을 느끼는 경우가 많다. 결과적으로 이들은 혼잡 시간대를 피하려는 선택을 하게 되며, 이는 이동권 침해로 이어지기도 한다. 공공교통이 포용적 기능을 수행하기 위해

서는 이러한 취약 계층의 이동 패턴과 요구에 대응할 수 있는 시스템 설계가 병행되어야 한다.

개인적인 차원에서도 필자는 이러한 문제를 일상 속에서 체감하게 되었다. 오후 늦은 시간 수업을 마치고 지하철을 타기 위해 승강장에 도착하면, 앞서 도착한 수많은 승객으로 인해 밀폐된 공간에서의 불쾌감, 이동의 제약, 소음과 열기 등으로 피로감이 배가되었다. 이에 따라 자연스럽게 도서관이나 카페 등에서 시간을 보내며 혼잡이 다소 줄어든 시간대를 기다렸다가 이동하는 습관을 형성하게 되었고, 이는 이동 효율을 크게 높일 수 있다는 체험적 인식으로 이어졌다.

이러한 경험을 통해 필자는 단순한 이동 시간 단축뿐만 아니라, ‘쾌적함’이라는 질적 요소가 이동 경험에 얼마나 중요한지를 실감하게 되었으며, 나아가 “특정 시간대의 혼잡도를 예측할 수 있다면 보다 전략적이고 능동적인 이동 계획이 가능하지 않을까?”라는 의문을 품게 되었다. 이는 본 연구의 출발점이자 문제의식의 핵심으로, 대중교통 시스템의 진화가 단순한 정시성과 운행 간격 개선에 머무르지 않고, 사용자 경험과 맞춤형 이동 정보 제공으로 확장되어야 함을 시사한다.

현재 네이버지도, 카카오맵, 서울시 교통정보포털(TOPIS) 등에서는 실시간 또는 근접 실시간 혼잡도 정보를 일부 제공하고 있으나, 이는 현재 상황에 대한 정적 정보에 불과하다. 다시 말해, 사용자가 이동 계획을 사전에 수립하거나, 미래 시간대의 혼잡도를 예측하여 능동적으로 대응할 수 있도록 지원하지는 않는다. 예컨대, 사용자가 “오늘 오후 6시경 ○○역에서 ○○역까지 이동할 계획인데 어느 시간대가 덜 혼잡할까?”라는 질문을 했을 때, 이에 명확히 답해줄 수 있는 시스템은 현재 존재하지 않는다.

이러한 공백은 기술적으로 충분히 해소 가능하다. 과거의 방대한 이용 데이터를 기반으로 한다면 시간대별, 노선별, 요일별, 공휴일 여부 등에 따른 혼잡도 패턴을 예측하는 것이 가능하며, 이를 바탕으로 미래의 혼잡도를 추정할 수 있다. 나아가 이러한 예측 정보를 활용하여 사용자의 목적지, 출발 시간, 이동 수단 선호 등을 고려한 개인 맞춤형 시간대 추천 시스템을 구현한다면, 단순한 교통정보 제공을 넘어 사용자 중심의 능동적인 이동 전략 수립을 지원하는 실용적인 시스템으로 발전할 수 있다.

본 논문은 이러한 문제의식과 실질적인 필요성에 기반하여, 서울시 지하철 7호선을 중심으로 시간대별 혼잡도 예측 모델을 구축하고, 예측 결과를 기반으로 혼잡도가 낮은 시간대를 사용자에게 추천하는 시스템을 설계하는 것을 주요 목표로 한다. 이를 위해 서울시에서 공개한 지하철 승하차 데이터와 시간 정보, 공휴일 여부, 요일 등의 변수를 통합하여 학습 데이터를 구성하고, 선형 회귀, XGBoost 등의 머신러닝 모델

을 비교 실험하여 최적의 예측 모델을 도출하였다. 이후 이를 기반으로 사용자가 이동하고자 하는 구간과 시간대에 대해 대체 시간대를 추천하는 기능까지 구현하였다.

본 연구의 의의는 단순히 혼잡도 예측 정확도를 높이는 것에 그치지 않고, 그 예측 결과를 활용하여 실제 사용자에게 도움이 되는 정보로 환원하는 데 있다. 이는 대중교통 정보 시스템이 수동적인 정보 나열에서 벗어나, 능동적인 **‘결정 지원 시스템(Decision Support System)’**으로 진화해야 한다는 하나의 방향성을 제시한다. 또한 교통약자의 이동권 보장, 사회적 약자 친화적 교통 정책 설계, 도시 운영의 효율성 제고 등 공공적 가치 실현 측면에서도 실질적인 기여 가능성이 크다.

따라서 본 논문은 기술적 구현을 넘어서, 사회적, 정책적 함의까지 고려한 교통 정보 시스템의 새로운 패러다임을 제안하고자 하며, 이는 향후 스마트시티 기반의 교통 인프라 설계나 교통 서비스 맞춤화 전략에 중요한 기초자료로 활용될 수 있을 것이다.

2. 관련연구

지하철 혼잡도 예측을 위한 연구는 지속적으로 발전해왔으며, 기존의 접근 방식은 크게 통계 기반 예측 기법과 머신러닝 기반 기법으로 나뉜다. 통계 기반 기법은 주로 시계열 데이터를 분석하여 미래의 혼잡도를 예측하는 방식으로, 대표적으로 ARIMA(Autoregressive Integrated Moving Average), SARIMA(Seasonal ARIMA)와 같은 전통적인 시계열 분석 기법이 활용되어 왔다. 이러한 방법은 시간의 흐름에 따른 데이터의 추세와 계절성을 반영하여 안정적인 예측을 가능하게 하지만, 복잡한 패턴이나 비선형성이 존재하는 현실 데이터를 완벽히 반영하기에는 한계가 존재한다.

이에 따라 최근에는 Decision Tree, Random Forest, Support Vector Machine(SVM), Gradient Boosting 계열의 XGBoost, LightGBM 등 다양한 머신러닝 모델이 혼잡도 예측 문제에 적용되고 있으며, 특히 비선형적 관계를 효과적으로 포착할 수 있는 트리 기반 모델들이 높은 예측 성능으로 주목받고 있다. 이러한 모델들은 시간, 요일, 공휴일 여부, 계절 등의 다양한 특성 변수(feature)를 활용하여 예측 정확도를 높일 수 있는 장점이 있으며, 기존 통계적 방법보다 더 유연하고 정교한 모델링이 가능하다.

서울시를 중심으로 한 국내 연구들 또한 이러한 추세에 부응하고 있다. 서울연구원(2020)에서는 시간대별 승하차 인원 통계를 기반으로 지하철 혼잡도를 계량화하고, 이를 바탕으로 도시교통계획 수립 및 정책 제언에 활용한 바 있다. 또한, 서울시 빅데이터 캠퍼스나 교통정보포털(TOPIS) 등을 통해 제공되는 공공데이터를 기반으로,

특정 노선이나 역 구간에서의 유동인구 패턴 분석 및 예측 연구가 진행되어 왔다.

한편, Kaggle, Dacon과 같은 데이터 분석 경진대회 플랫폼에서는 대중교통의 혼잡도 예측 문제를 회귀 문제(regression task)로 설정하고 다양한 알고리즘 간의 성능 비교를 시도한 바 있으며, 이 과정에서 시간 인코딩 방법(예: cyclical encoding), 누적 탑승객 수, 정류장 간 이동 시간 등의 파생 변수 생성이 예측 성능 향상에 중요한 요인으로 작용하였다.

최근에는 딥러닝 기반의 시계열 예측 기법, 특히 LSTM(Long Short-Term Memory), GRU(Gated Recurrent Unit)과 같은 RNN 기반 모델이 적용되기도 한다. 이러한 모델은 장기적인 시간 의존성을 효과적으로 포착할 수 있어 시계열 예측에서 강력한 성능을 보이나, 해석 가능성 부족, 학습 시간 증가, 연산 비용 상승 등의 단점으로 인해 실시간 혹은 실용적인 시스템 구현에는 제약이 따르기도 한다. 따라서 실제 혼잡도 예측 시스템을 구축하는 데 있어서는, 높은 성능과 빠른 추론이 가능한 트리 기반 모델들이 여전히 주로 선택되는 경향이 있다.

기존 연구의 공통된 한계는 대부분 예측 모델의 개발과 그 정확도 향상에 집중되어 있으며, 예측된 결과를 실제 사용자 경험 개선에 활용하는 데까지 나아가지 못했다는 점이다. 특히, 예측 정보를 바탕으로 사용자가 이동 계획을 능동적으로 조정할 수 있도록 지원하는 ‘추천 시스템’으로의 확장은 아직 활발히 이루어지지 않고 있다.

본 연구는 기존 연구의 이러한 한계를 보완하고자, 예측된 혼잡도 정보를 기반으로 실질적인 시간대 추천 기능을 구현하는 데 초점을 맞추었다. 이는 단순히 높은 예측 정확도를 달성하는 것을 넘어, 실제 사용자에게 유용한 정보를 제공하고, 이동 전략에 있어 보다 능동적인 의사결정을 가능하게 함으로써 대중교통 이용 경험의 질을 실질적으로 향상시키는 것을 목표로 한다. 예측과 추천 기능의 통합은 기존 연구와의 차별성을 보여주는 핵심 요소이며, 향후 사용자 중심의 스마트 교통 시스템으로의 발전 가능성을 제시한다는 점에서 학술적·실용적 의미가 크다.

3. 데이터 소개 및 문제 정의

3.1 데이터 소개

본 연구는 서울교통공사에서 제공하는 2022년부터 2024년까지의 지하철 관련 통계 데이터를 활용하였다. 약 300만 건 이상의 데이터로 구성되어 있으며, 이는 크게 두 가지 유형으로 나뉜다. 첫 번째는 지하철 역사별 시간대별 이용량 통계로, 개찰구를 통과하여 역사 내로 진입한 승객 수(승차)와 개찰구를 통과하여 역사 밖으로 나간 승객 수(하차)를 측정한 데이터이며, 일별 정확한 날짜를 기준으로 1시간 단위로 측정된

다.

두 번째는 지하철 역사별 시간대별 혼잡도 통계로, 특정 기간 동안 승객들의 승차역과 하차역을 파악하고 예상 경로를 추정하여 산출된 값이다. 혼잡도 지수는 (승차인원 - 하차인원) / 역사 수용인원 $\times$ 100으로 정의되며, 34는 좌석이 가득 찬 상태, 100 이상은 입석까지 만원 상태, 120 이상은 매우 혼잡한 상태를 의미한다. 혼잡도 통계는 원래 30분 단위로 측정되었으나, 분석을 위해 1시간 단위로 변환하여 사용하였다. 수집된 데이터에 대해서는 이상치 제거, 범주형 변수 인코딩, 그리고 시간대 인코딩(순서 인코딩, 원-핫 인코딩, 주기 인코딩)과 같은 전처리 과정을 수행하였다.

3.2 문제 정의

본 연구의 핵심 목표는 지하철 이용자의 출발역, 도착역, 요일, 시간대, 방향 정보를 기반으로 해당 시간대의 혼잡도를 예측하는 것이다. 이 문제는 정량적인 연속형 값을 예측하는 지도학습 기반의 회귀 문제로 정의할 수 있으며, 입력값으로 출발역, 도착역, 요일, 시간대, 방향 등을 활용하여 혼잡도를 예측하는 것이다. 출력값은 0~150 사이의 연속적인 수치로, 혼잡도 지표를 나타낸다.

4. 초기 연구 방향

4.1 제공 데이터의 구조적 특성

서울교통공사에서 제공하는 지하철 혼잡도 데이터는 시간적 단위에 따라 상이한 구조를 보인다. 2010년대의 혼잡도 데이터는 2년 단위로 수집되었고, 2021년부터 2023년까지는 1년 단위로, 2024년부터 현재까지는 분기별로 데이터를 수집한다. 2010년대 데이터는 수집 기간이 넓어 분석에서 제외하였으며, 2021년 데이터는 코로나19로 인한 사회적 거리두기와 재택근무 확산으로 혼잡도 패턴에 큰 변동이 있었을 것으로 판단하여 분석에서 제외하였다. 이에 따라 본 연구에서는 비교적 안정적인 혼잡도 패턴을 보이는 2022년부터 2024년까지의 3년간 데이터를 중심으로 분석을 진행하였다.

분석 대상 기간 내에서도 2022년과 2023년의 경우 연간 평균 지하철 혼잡도 데이터로 제공되는 반면, 2024년 데이터는 1분기부터 4분기까지 분기별로 세분화된 형태로 제공된다. 이러한 데이터 구조의 불일치는 시계열 분석 및 예측 모델 구축에 있어 중대한 장애요인으로 작용한다. 분석의 일관성과 모델의 정확성을 확보하기 위해서는 동일한 기간 단위의 데이터를 사용하는 것이 필수적이다. 따라서 필자는 두 가지 접근 방안을 고려하였다. 첫 번째는 2024년의 분기별 데이터를 연간 평균으로 통합하는 방법이고, 두 번째는 2022년과 2023년의 연간 데이터를 분기별로 분할하는 방법이다. 필자는 데이터 손실 최소화 원칙에 따라 2022년과 2023년의 연간 데이터를 분기별로 분할하는 방법을 채택하였다. 2024년의 분기별 데이터를 연간 평균으로 통합할 경우,

계절적 변동성과 분기별 특성 정보가 소실될 우려가 있었기 때문이다. 이러한 판단은 시계열 데이터의 정보 보존 측면에서는 합리적이었으나, 후에 밝혀진 바와 같이 데이터의 근본적인 수집 방식에 대한 이해 부족에서 비롯된 오류였다.

4.2 최소제곱법 기반 데이터 분할 방법론

연간 혼잡도 데이터를 분기별로 분할하기 위해 승하차량 데이터와의 선형 관계를 가정한 모델을 설계하였다. 기본 가정은 지하철 혼잡도가 승하차량의 변화와 선형적 상관관계를 가진다는 것이었다. 이에 따라 다음과 같은 수식을 도출하였다:

$$\text{분기별 지하철 혼잡도} = \text{연간 지하철 혼잡도} + \alpha \times [(\text{분기별 승차량} - \text{분기별 하차량}) - (\text{연평균 승차량} - \text{연평균 하차량})]$$

여기서 α 는 최소제곱법을 통해 추정되는 계수로, 승하차량 변화가 혼잡도에 미치는 영향의 크기를 나타낸다. 이 계수의 결정계수(R^2)가 높을 경우, 선형 관계가 유의미하다고 판단하여 해당 α 값을 활용한 데이터 분할이 가능할 것으로 예상하였다.

α 계수 추정의 정확성을 높이기 위해 3가지 상이한 접근법을 적용하였다. 첫째, 전체 역을 대상으로 하는 단일 α 계수 추정법, 둘째, 시간대별로 차별화된 α 계수를 적용하는 방법, 셋째, 역사별로 개별 α 계수를 적용하는 방법 등을 시도하였다. 각 방법은 데이터의 공간적, 시간적 특성을 고려한 세분화된 접근을 의도하였다.

4.3 실험 결과 및 방법론의 한계

3가지 접근법 모두 예상과 달리 극도로 낮은 결정계수가 도출되었다. 전체 역을 대상으로 구한 단일 α 의 R^2 는 -0.3340, 시간대별로 구한 α 의 R^2 는 -3.0866, 역사별로 구한 α 의 R^2 는 -4.1277로 음의 결정계수 값을 보였다.

	단일 α	시간대별 α	역사별 α
R^2	-0.3340	-3.0866	-4.1277

이러한 결과는 승하차량과 혼잡도 간의 선형 관계 가정이 성립하지 않음을 명확히 보여준다. 특히 모든 경우에서 결정계수가 0보다 낮게 나타난 것은 설정한 모델이 실제 데이터의 변동성을 설명하지 못할 뿐만 아니라, 평균값보다도 못한 예측 성능을 보인다는 의미이다. 음의 결정계수는 통계학적으로 모델이 데이터의 패턴을 전혀 파악하지 못하고 있음을 의미하며, 이는 단순히 계수 추정의 문제나 식 설정의 오류가 아니라, 근본적인 기본 가정 자체의 오류를 시사한다. 지하철 혼잡도와 승하차량 간의 관계가 연구진이 가정한 선형 모델로는 설명될 수 없는 복잡한 비선형적 특성을 가지고 있거나, 아예 다른 요인들에 의해 결정될 가능성이 제기되었다.

또한, 모델을 학습할 노선을 선택하는 과정에서 초기에는 필자가 자주 이용하는 3호선을 중심으로 분석을 시작하였다. 그러나 분석을 진행하면서 혼자서 놓친 점들이 있을 수 있다는 생각이 들었고, 학생들이 많이 이용하는 7호선이라면 주변으로부터 다양한 조언과 피드백을 얻을 수 있을 것이라 판단하여 이후의 분석은 7호선을 대상으로 수행하였다.

4.4 데이터 수집 방식 탐구 및 근본적 문제 발견

실험 결과의 이상함을 해결하기 위해 서울교통공사에 직접 문의를 진행하였다. 처음에 온라인 문의 시스템을 이용하여 질문을 남겼고, 추가적인 궁금증은 담당자의 번호로 직접 연락을 취하여 데이터 수집 방식에 대한 구체적인 정보를 확보하고자 하였다. 이러한 직접적인 소통은 연구의 기초가 되는 데이터에 대한 정확한 이해를 위해 필수적인 과정이었다.

서울교통공사로부터 확인한 실제 데이터 수집 방식은 필자의 가정과 근본적으로 달랐다. 2024년 지하철 혼잡도 데이터는 1분기부터 3분기까지는 특정 1주일의 혼잡도를 실측한 것이며, 4분기는 특정 1개월의 혼잡도를 실측한 결과였다. 더욱 중요한 사실은 2022년과 2023년의 연간 지하철 혼잡도 데이터가 연간 평균 데이터가 아닌, 매년 11월의 특정 1주일간 수집된 데이터라는 점이었다.

이러한 수집 방식의 차이는 연구진이 시도한 데이터 분할 접근법이 근본적으로 잘못되었음을 명확히 보여준다. 11월 한 주의 데이터를 연간 데이터로 간주하여 분기별로 분할하려는 시도는 데이터의 실제 특성을 완전히 무시한 것이었다. 각 분기별 데이터 역시 해당 분기를 대표하는 표본 기간의 데이터이므로, 서로 다른 시점과 기간의 데이터를 선형 변환으로 연결하려는 시도는 통계학적으로 무의미했다.

제목	지하철 혼잡도 데이터 관련 문의드립니다.		
분류	문의		
작성일	2025-05-20 16:37	처리기한	2025-05-28
처리단계	답변완료	접수부서	안전계획처
지하철 혼잡도 데이터를 이용하여 데이터 분석을 진행 중인 대학교 3학년 학생입니다. 자료실에 있는 지하철 혼잡도의 분기별 및 연간 데이터에서 혼잡도를 측정할 정확한 시점이 궁금하여 연락드립니다. 특정 역에서의 혼잡도로 적힌 수치가 역에서 승하차를 마친 후 다음 역으로 이동하는 과정에서 혼잡도가 맞는지 알고 싶습니다. 또한, 혼잡도를 어떤 방식으로 측정했는지 알려주시면 감사하겠습니다.			
첨부파일			
처리결과			
처리부서	안전계획처	처리자	홍보석
처리완료일	2025-05-22 08:58	처리자메일	boseekdowk@seoulmetro.co.kr
안녕하십니까? 귀하께서 고객의소리를 통해 신청하신 민원에 대한 검토 결과를 다음과 같이 알려드립니다. 귀하의 민원내용은 "지하철 혼잡도 측정 시간 및 혼잡도 측정 방식"에 관한 것으로 이해되며, 귀하의 질의사항에 대해 검토한 의견은 다음과 같습니다. 가. 공식 홈페이지 지하철 혼잡도(월/일당~혼잡도~월/일당) 데이터의 측정기간은 다음과 같습니다. 1) 2024년 3분기 : 24.09.23(월) ~ 09.29(월) / 7일 간 2) 2024년 4분기 : 24.11.01(화) ~ 11.30(토) / 30일 간 3) 2025년 1분기 : 25.03.17(월) ~ 03.23(월) / 7일 간 나. 특정 역의 혼잡도 데이터는 승차 후 다음 역으로 이동하는 열차의 혼잡도 값입니다. 예시) 2호선 방배역~위산 143.0미센터 : 방배역 승차 후 시호역으로 이동하는 열차의 혼잡도 다. 혼잡도 측정방식은 다음과 같습니다. 1) 교통카드 승차 내역을 기반으로 승객의 출발역~도착역까지 경로 산정 2) 최적 경로를 기반으로 승객의 탑승열차 후진에 따른 열차 탑승인원 산정 3) 혼잡도 평가에 의한 열차 혼잡도 산출 귀하의 질문에 만족스러운 답변이 되었기를 바라며, 답변 내용에 추가 설명이 필요한 경우 서울교통공사 안전계획처 명채영 대리(☎02-6311-2063)에게 연락주시면 친절히 안내해 드리겠습니다. 감사합니다.			

< 02-6311-2063

5월 22일 목요일

☎ 오후 5:36
발신전화, 7분 22초

그림 1. 서울교통공사 혼잡도 데이터 문의 및 답변 내용, 그림 2. 서울교통공사 데이터 담당자와의 통화 기록

5. 수정된 연구 방향

5.1 데이터 정합성 확보 및 이중 모델링 전략 수립

서울교통공사에 문의를 통해 2022년, 2023년 11월 및 2024년 분기별 혼잡도 측정의 정확한 조사 일자를 확보함으로써 데이터 정합성 문제를 근본적으로 해결하였다. 각 연도의 혼잡도 데이터가 실제로는 특정 주간의 집중 측정 결과임이 확인되면서, 해당 기간의 승하차량 데이터와 정확히 매칭시키는 새로운 접근법이 도출되었다. 이는 기존의 가상 분기 분할 방식에서 벗어나 실제 측정 시점의 데이터를 활용함으로써 모델 입력값과 출력값의 시간적 일치성을 확보한 결정적 전환점이 되었다.

필자는 미래 혼잡도 예측 시스템 구축을 위해 이중 모델링 전략을 채택하여 시스템의 복잡성을 효과적으로 관리하고자 하였다.

5.1.1 미래 승하차량 예측 모델

첫 번째 모델은 시계열 예측 기법을 적용하여 과거 승하차량 패턴으로부터 미래의 승하차량 트렌드를 추정하는 구조로 개발할 예정이다. 승하차 데이터는 일별, 시간대별로 정확한 값을 알고 있으므로, 충분한 데이터를 바탕으로 시계열 예측을 시도해볼 수 있다. 특히, 특정 승하차량 값이 높거나 낮은 경우를 단순한 이상치 제거 또는 평균값 대체가 아닌, 그 원인 분석까지 시도하여 모델의 예측 정확도를 높일 수 있다. 이 모델은 시간의 흐름에 따른 승하차량의 변화를 예측하여, 미래 시점의 혼잡도 예측에 필요한 핵심 입력값을 제공한다.

5.1.2 혼잡도 예측 모델

두 번째 모델은 역사별, 시간대별 승하차량 데이터(Input)를 기반으로 해당 시점의 혼잡도(Output)를 예측하는 회귀 모델로 설계되었다. 혼잡도는 측정된 날짜 및 시간을 정확히 알고 있으므로, 이에 해당하는 실측 승하차 데이터와 정밀하게 페어링하여 모델 학습에 활용할 수 있다. 이 모델은 주어진 승하차량 데이터와 기타 요인들(역명, 요일, 시간대 등)을 바탕으로 혼잡도 지수를 산출하는 역할을 담당한다.

5.1.3 모델 결합을 통한 시스템 구축

이 두 모델의 직렬 연결을 통해, 과거 승하차 데이터를 기반으로 미래의 승하차량을 예측하고, 이를 통해 최종적인 미래 혼잡도 예측이 가능한 체계를 구축할 계획이다.

5.2 모델 학습을 위한 feature 전처리

학습 및 테스트에 사용한 feature는 역명, 요일 구분, 승차 인원, 하차 인원, 시간대이다. 역명은 지하철 노선도의 역 순서에 따라 레이블 인코딩을 수행하고, 요일 구분은 평일, 토요일, 공휴일로 이루어진 범주형 변수를 원-핫 인코딩을 수행하였다.

06시부터 24시까지 1시간 단위로 이루어진 시간대는 지하철 혼잡도 데이터를 다룰 때 모델의 성능 향상에 매우 중요한 요소라고 판단하였고 어떠한 방식으로 분석하는 것이 좋다고 단정할 수 없어 3가지 방식으로 모두 인코딩을 수행하였다.

5.2.1 원-핫 인코딩

원-핫 인코딩은 각 시간대를 독립된 범주형 변수로 처리하여 이진 벡터로 표현하는 방식이다. 예를 들어, 24시간의 시간대가 있다면 24개의 독립된 컬럼으로 표현된다. 이 방식은 직관적이며 모델이 각 시간대마다 독립적인 특성을 학습할 수 있다는 장점이 있다. 그러나 차원이 급격히 증가하여 계산 부담이 크고, 데이터가 희소해지는 단점이 존재한다.

label	구분_상선	구분_하선	요일_공휴일	요일_토요일	요일_평일	시간대_06~07	시간대_07~08	시간대_08~09	시간대_09~10	...	시간대_16~17	시간대_17~18	시간대_18~19	시간대_19~20	시간대_20~21	시간대_21~22	시간대_22~23	시간대_23~24	승차	하차
0	0	True	False	True	False	False	True	False	False	False	...	False	False	False	False	False	False	False	118.0000000000	69.0000000000
1	0	False	True	True	False	False	True	False	False	False	...	False	False	False	False	False	False	False	118.0000000000	69.0000000000
2	0	True	False	False	False	True	True	False	False	False	...	False	False	False	False	False	False	False	830.3333333333	147.8095238095
3	0	False	True	False	False	True	True	False	False	False	...	False	False	False	False	False	False	False	830.3333333333	147.8095238095
4	0	True	False	False	True	False	True	False	False	False	...	False	False	False	False	False	False	False	224.0000000000	86.2000000000
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
4531	41	False	True	True	False	False	False	False	False	False	...	False	False	False	False	False	False	True	6.7500000000	13.2500000000
4532	41	True	False	False	False	True	False	False	False	False	...	False	False	False	False	False	False	True	9.8571428571	25.2380952381
4533	41	False	True	False	False	True	False	False	False	False	...	False	False	False	False	False	False	True	9.8571428571	25.2380952381
4534	41	True	False	False	True	False	False	False	False	False	...	False	False	False	False	False	False	True	9.4000000000	23.4000000000
4535	41	False	True	False	True	False	False	False	False	False	...	False	False	False	False	False	False	True	9.4000000000	23.4000000000

4536 rows × 26 columns

그림 3. 원핫 인코딩을 수행한 혼잡도 데이터

5.2.2 레이블 인코딩(Label Encoding)

레이블 인코딩은 각 시간대를 단순한 정수 값으로 표현한다. 예를 들어, 6시를 0, 8시를 2 등으로 매핑하는 방식이다. 이 방식은 구현이 쉽고 차원을 증가시키지 않는다는 장점이 있다. 하지만 시간대 간의 순서가 임의로 설정되기 때문에 실제로 존재하는 주기적인 관계를 제대로 반영하지 못할 수 있다는 단점이 있다.

	label	구분_상선	구분_하선	요일구분_공휴일	요일구분_토요일	요일구분_평일	시간대_label	승차	하차
0	0	True	False	False	False	True	0	830.3333333333	147.8095238095
1	0	False	True	False	False	True	0	830.3333333333	147.8095238095
2	0	True	False	False	True	False	0	224.0000000000	86.2000000000
3	0	False	True	False	True	False	0	224.0000000000	86.2000000000
4	0	True	False	True	False	False	0	118.0000000000	69.0000000000
...	...	...	...	...	...	...	...	...	...
4531	41	False	True	False	False	True	17	9.8571428571	25.2380952381
4532	41	True	False	False	True	False	17	9.4000000000	23.4000000000
4533	41	False	True	False	True	False	17	9.4000000000	23.4000000000
4534	41	True	False	True	False	False	17	6.7500000000	13.2500000000
4535	41	False	True	True	False	False	17	6.7500000000	13.2500000000

4536 rows × 9 columns

그림 4. 레이블 인코딩을 수행한 혼잡도 데이터

5.2.3 주기 인코딩(Cyclic Encoding)

주기 인코딩은 시간 정보를 주기적인 속성으로 다루기 위해 삼각함수(sin, cos)를 이용한다. 이는 시간대 정보를 원형 시계처럼 표현하여 주기성을 명확히 반영한다. 본 연구에서는 출근 시간인 8시와 퇴근 시간인 18시를 기준으로 혼잡도가 최대값을 가지도록 설정하였으며, 이 시간에서 멀수록 낮은 값을, 가까울수록 높은 값을 갖도록 인코딩을 수행하였다. 이러한 방식은 시간대 간의 주기성을 효과적으로 반영하고 차원을 낮추는 장점이 있어, 수업 시간에 다루지 않았음에도 불구하고 모델 성능 향상을 위해 추가적으로 적용하게 되었다.

	label	구분_상선	구분_하선	요일구분_공휴일	요일구분_토요일	요일구분_평일	시간대_label	승차	하차	시간대_sine	시간대_cosine
0	0	True	False	False	False	True	0	830.3333333333	147.8095238095	0.7660444431	0.6427876097
1	0	False	True	False	False	True	0	830.3333333333	147.8095238095	0.7660444431	0.6427876097
2	0	True	False	False	True	False	0	224.0000000000	86.2000000000	0.7660444431	0.6427876097
3	0	False	True	False	True	False	0	224.0000000000	86.2000000000	0.7660444431	0.6427876097
4	0	True	False	True	False	False	0	118.0000000000	69.0000000000	0.7660444431	0.6427876097
...	...	...	...	...	...	...	...	...	...	...	...
4531	41	False	True	False	False	True	17	9.8571428571	25.2380952381	0.5000000000	0.8660254038
4532	41	True	False	False	True	False	17	9.4000000000	23.4000000000	0.5000000000	0.8660254038
4533	41	False	True	False	True	False	17	9.4000000000	23.4000000000	0.5000000000	0.8660254038
4534	41	True	False	True	False	False	17	6.7500000000	13.2500000000	0.5000000000	0.8660254038
4535	41	False	True	True	False	False	17	6.7500000000	13.2500000000	0.5000000000	0.8660254038

그림 5. 주기 인코딩을 수행한 혼잡도 데이터

구체적인 구현은 다음과 같다. 먼저, 원본 데이터의 시간대별 컬럼을 melt 함수를 사용하여 행으로 확장한다. 이후 각 시간대 문자열에서 시작 시간을 정수형으로 추출한다. 마지막으로, 정의된 주기(예: 24시간)와 피크 시간(출근 시간, 퇴근 시간)을 기반으로 삼각함수를 적용하여 사인(sine) 및 코사인(cosine) 변환을 수행한다. 이 과정

을 통해 시간대의 주기적 특성이 반영된 두 개의 새로운 특성(_sine, _cosine)이 생성된다.

6. 학습 수행 및 성능 확인

이전 데이터 분할 방법론에서 낮은 결정계수(R^2)가 도출되어 승하차량과 혼잡도 간의 비선형적 특성이 강하게 나타날 것이라는 판단하에, 필자는 선형 모델과 비선형 모델의 성능을 비교하고자 하였다. 이에 따라 선형 회귀 모델과 XGBoost 회귀 모델을 기본 모델로 선정하여 학습을 수행하였다.

6.1 기본 모델 학습 및 성능 분석

6.1.1 선형 회귀 모델 적용

선형 회귀 모델은 그 특성상 데이터 간의 선형적 관계를 가정하는 전통적인 통계학적 접근법이다. 이는 해석이 용이하고 계산 효율성이 높다는 장점을 가지며, 다중공선성 문제 해결을 위한 정규화 기법 적용 가능성을 고려할 수 있다. 본 연구에서는 모델 개선의 기준점을 마련하기 위한 기본 성능 지표 확보를 목적으로 선형 회귀 모델을 적용하였다.

6.1.2 XGBoost 회귀 모델 적용

비선형 회귀 모델로는 XGBoost를 선택하였다. XGBoost는 트리 기반 앙상블 기법으로, 복잡한 비선형 관계 학습에 특히 우수하다는 장점이 있다. 또한, 경사 부스팅 방식을 통해 잔차 개선을 반복 학습함으로써 모델의 예측 정확도를 높일 수 있으며, 조기 종료 기능이 내장되어 있어 과적합 방지에도 효과적이다. 이전 실험에서 선형 관계 가정의 한계를 명확히 확인했기 때문에, 비선형 데이터 학습에 효과적인 XGBoost가 혼잡도 예측에 적합하다고 판단하였다.

6.1.3 성능 분석

표 1. 시간 인코딩 방식별 모델 성능 비교 (MSE, R^2 및 MAE)

	Linear Regression			XGBoost Regression		
	MSE	R^2	MAE	MSE	R^2	MAE
원-핫 인코딩	271.1945	0.2838	12.1904	21.2626	0.9438	3.2731
레이블 인코딩	286.5657	0.2432	12.6769	14.6151	0.9614	2.6833
주기 인코딩	279.1123	0.2628	12.3811	15.0154	0.9603	2.7279

기본 학습 수행 결과, 모든 인코딩 방식에서 XGBoost 회귀 모델이 선형 회귀 모델보다 월등히 우수한 성능을 보였다. 특히 [표 1]에서 볼 수 있듯이, 레이블 인코딩 방식에서 XGBoost의 R^2 값이 0.9614로 가장 높게 나타났으며, MAE는 2.6833을 기록

했다. XGBoost의 평균 MSE는 선형 모델 대비 약 90% 낮은 성능 개선 효과를 보였다. 이러한 결과는 지하철 혼잡도 예측에 있어 비선형 모델인 XGBoost의 효과적인 학습 능력을 명확히 보여준다. 또한, 시간 인코딩 방식에 있어서는 원-핫 인코딩 방식보다 레이블 인코딩과 주기 인코딩 방식이 더 나은 성능을 나타냈으며, 이 두 방식 간에는 성능 차이가 미미함을 확인하였다.

6.2 모델 고도화 및 하이퍼파라미터 튜닝

기본 모델 학습 이후 성능 개선을 위해 릿지 회귀와 XGBoost 모델에 대한 고도화 학습 및 하이퍼파라미터 튜닝을 수행하였다.

6.2.1 릿지 회귀 최적화

선형 회귀 모델의 한계를 극복하고 성능을 향상시키기 위해 L2 정규화 기법이 적용된 릿지 회귀를 사용하였다. 릿지 회귀 최적화를 위해 특징(feature) 간의 비선형적 관계 및 상호작용을 반영하고자 2차 다항식 변환(PolynomialFeatures)을 수행하였다. 또한, 데이터 스케일의 차이로 인한 문제와 과적합을 방지하기 위해 표준화(StandardScaler)를 적용한 후 L2 정규화를 강화하였다. 모델의 규제 강도를 조절하는 최적의 α 값(0.001부터 100까지)을 탐색하기 위해 그리드 서치(Grid Search)를 활용하였다.

6.2.2 XGBoost 하이퍼파라미터 튜닝

XGBoost 모델의 예측 성능을 극대화하고 과적합을 방지하기 위해 주요 하이퍼파라미터를 튜닝하였다. max_depth는 트리의 복잡도를 제어하는 중요한 파라미터로, 모델이 너무 깊어져 과적합되는 것을 방지하고자 7로 설정하였다. learning_rate는 학습 속도와 정확도 간의 균형을 맞추기 위해 0.1로 선택하였다. subsample(0.8)과 colsample_bytree(0.6)는 각각 학습 시 사용되는 데이터 샘플 및 특징 샘플링 비율을 조절함으로써 과적합을 방지하는 데 중점을 두었다. 마지막으로, 모델이 훈련 데이터에 과적합되는 것을 막기 위해 100라운드 동안 성능 개선이 없을 경우 학습을 조기 종료하도록 조기 종료 조건을 설정하였다.

6.2.3 고도화 학습 결과

표 2. 고도화 학습 모델별 성능 비교 (MSE, R^2 및 MAE)

	Linear_Regression			XGBoost Regression		
	MSE	R^2	MAE	MSE	R^2	MAE
원-핫 인코딩	237.8510	0.3718	11.6448	12.2907	0.9675	2.4850
레이블 인코딩	286.5899	0.2431	12.6848	15.5515	0.9589	2.6806
주기 인코딩	286.5899	0.2431	12.6848	9.9463	0.9737	2.2229

고도화 학습 결과, XGBoost 모델은 주기 인코딩 방식에서 R^2 값이 0.9737로 가장 높게 나타났으며, MAE는 2.2229를 기록하며 최적의 성능을 달성하였다. 이는 초기 학습 단계에서 가장 높은 성능을 보였던 레이블 인코딩 방식보다 향상된 결과이다. 반면, 릿지 회귀 모델은 원-핫 인코딩 방식에서 R^2 가 0.3718로 소폭 상승했으나, XGBoost 모델과 비교하여 여전히 현저히 낮은 예측 성능을 보였다. 이러한 결과는 복잡한 비선형 관계를 가진 지하철 혼잡도 예측에 XGBoost와 주기 인코딩의 조합이 가장 효과적임을 시사한다.

6.3 다른 계절 데이터에 대한 모델 성능 검증

본 연구에서 최적화된 XGBoost 모델의 일반화 성능을 확인하고자, 2024년 3월, 6월, 9월의 혼잡도 데이터를 활용하여 추가적인 성능 검증을 수행하였다. 이는 기존 11월 집중 측정 데이터에 국한된 검증의 한계를 보완하고, 다른 계절적 특성을 가진 데이터에 대한 모델의 예측 능력을 평가하기 위함이다.

표 3. 2024년 분기별 XGBoost 모델 성능 (MSE, R^2 및 MAE)

	XGBoost		
	MSE	R^2	MAE
3월	10.8984	0.9726	2.3413
6월	13.9197	0.9602	2.6499
9월	11.9066	0.9698	2.2948

[표 3]에서 나타난 바와 같이, 2024년 3월, 6월, 9월 데이터에 대한 검증에서도 XGBoost 모델은 높은 예측 성능을 유지하였다. 특히 3월 데이터에서 R^2 0.9726, MAE 2.3413을 기록했으며, 9월 데이터에서는 R^2 0.9698, MAE 2.2948로 안정적인 성능을 보였다. 6월 데이터에서는 R^2 0.9602, MAE 2.6499를 기록하여 상대적으로 소폭 낮은 성능을 보였으나, 전반적으로 0.96 이상의 높은 R^2 값을 유지하며 모델의 예측 능력을 재확인할 수 있었다. 이는 최적화된 XGBoost 모델이 다양한 계절적 특성을 가진 데이터에 대해서도 준수한 일반화 성능을 가짐을 시사한다.

7. 연구 성과 종합 및 향후 발전 방향

7.1 본 연구의 성과 요약

본 연구는 서울시 지하철 7호선을 대상으로 시간대별 혼잡도를 예측하고, 예측 결과를 바탕으로 사용자에게 쾌적한 이동 시간대를 추천하는 시스템을 구축하는 것을 목표로 하였다. 이를 위해 서울교통공사에서 제공하는 2022년 11월, 2023년 11월, 2024년 분기별 혼잡도 데이터를 기반으로, 머신러닝 기반의 회귀 모델을 설계·학습·평가하였다.

모델링 과정에서는 다양한 시간 인코딩 방식과 특징 선택 전략을 실험하였으며, 그중에서도 주기 인코딩 기법(sin/cos)을 적용한 시간대 처리 방식이 모델의 예측 성능 향상에 결정적인

기여를 한 것으로 분석되었다. 이는 혼잡도의 시간적 주기성과 반복성을 반영할 수 있는 구조로, 단순 수치형 시간 변수를 사용하는 방식보다 정밀한 패턴 학습이 가능하게 하였다.

최종적으로 채택된 XGBoost 회귀 모델은 하이퍼파라미터 최적화를 통해 평균제곱오차(MSE) 9.9463, 결정계수(R^2) 0.9737이라는 우수한 예측 성능을 기록하였다. 이는 초기 선형 회귀 모델 대비 MSE 기준으로 약 96.3% 향상된 결과이며, 전체 혼잡도 변동의 97% 이상을 설명할 수 있는 수준의 정밀도를 의미한다. 이는 실제 환경에서의 혼잡도 예측 및 활용에 있어 충분한 신뢰성을 제공할 수 있는 수준으로 평가된다.

추가로, 모델의 일시적 과적합 가능성을 배제하기 위해 2024년 3월, 6월, 9월에 해당하는 독립 검증 데이터셋을 사용하여 평가를 실시하였다. 그 결과, 각각 R^2 0.9726, 0.9602, 0.9698의 높은 성능을 유지하였으며, 이는 학습 데이터와 다른 시기의 데이터에서도 일관된 예측력을 보여주는 모델의 강력한 일반화 능력을 입증하는 결과로 볼 수 있다.

이처럼 본 연구는 데이터 기반 분석, 모델 최적화, 실사용 가능성에 이르기까지 일관된 구조로 진행되었으며, 그 결과 기존 정보 제공 시스템이 해결하지 못한 '미래 혼잡 예측'과 '시간대 추천'이라는 실질적인 문제 해결 가능성을 실증적으로 제시하였다. 특히 예측 모델을 기반으로 사용자가 입력한 출발지, 목적지, 시간대 조건에 따라 혼잡도가 낮은 대체 시간대를 안내하는 시스템은 실제 응용 서비스로의 발전 가능성도 내포하고 있다.

이러한 성과는 기술적인 측면뿐만 아니라, 교통 정보 제공의 사용자 중심 전환이라는 점에서 사회적 가치와 실용적 의미를 동시에 갖는다고 평가할 수 있다.

7.2 방법론적 한계 및 개선 과제

본 연구의 모델은 2022년과 2023년 11월 특정 주간 데이터와 2024년 분기별 특정 주간/월 실측 데이터에 기반하여 학습 및 검증되었다. 비록 2024년 3월, 6월, 9월 데이터를 추가 활용하여 다른 계절적 특성을 반영하고자 노력하였으나, 이는 여전히 각 시점의 표본 데이터에 불과하여 연중 전체 혼잡도 패턴을 완벽하게 대표한다고 보기는 어렵다.

이러한 데이터셋의 부족은 혼잡도 데이터가 특정 기간 동안 승객들의 승차역과 하차역을 파악하고 최적의 노선을 예측하여 혼잡도를 추정하는 방식으로 수집되어 시간과 비용이 많이 소모되기 때문에 발생하는 근본적인 한계이다. 특히, 과거 2010년대에는 2년 단위로만 조사가 진행되었으며, 2020년부터 2021년까지의 데이터는 코로나19로 인한 사회적 거리두기 및 재택근무 확산으로 인해 데이터 신뢰도가 낮아 분석에서 제외되었기에, 실제 활용 가능한 혼잡도 데이터의 양은 더욱 제한적이었다. 따라서 모델의 일반화 능력 및 실제 운영 환경에서의 예측 견고성을 확보하기 위해서는 계절별, 월별 등 더욱 연속적이고 광범위한 실측 혼잡도 데이터를 확보하고 이를 기반으로 모델을 재학습하는 것이 필요하다. 또한, 현재 7호선 구간의 데이터만을 활용했기에 전 노선으로의 일반화 가능성 검증이 추가적으로 요구된다.

7.3 향후 발전 방향

향후 연구에서는 본 모델을 서울 지하철 2호선 순환선 및 9호선 급행선과 같이 이질적 특성

을 가진 노선으로 확장 적용하여 모델의 범용성을 검증할 예정이다. 2호선은 서울 도심을 순환하는 유일한 노선으로, 출퇴근 시간뿐만 아니라 주간에도 상업 및 업무 지구를 연결하여 상시적인 혼잡이 발생하며, 특정 방향으로의 편향 없이 양방향으로 균등한 수요가 나타나는 특징이 있다. 반면, 9호선 급행선은 짧은 시간에 장거리를 이동하는 승객이 많아 급격한 혼잡도 변화와 매우 높은 피크 혼잡도를 보이는 특징이 있다. 이러한 다양하고 복합적인 노선 특성에 모델을 적용함으로써, 본 연구의 예측 모델이 더 넓은 범위의 대중교통 환경에서도 유효함을 입증할 계획이다.

궁극적으로는 과거 승하차 데이터를 기반으로 미래 승하차량을 예측하는 시계열 모델을 구축하고, 이를 현재의 혼잡도 예측 모델과 직렬 연결하여 과거 승하차 데이터만으로 미래 혼잡도를 예측하는 시스템을 구현하는 것을 목표로 한다. 이를 통해 지하철 이용자에게 혼잡도 최소화 시간대를 추천하는 사용자 맞춤형 시스템을 완성할 계획이다.

8. 출처 및 참고문헌

지하철 혼잡도 데이터

(<https://data.seoul.go.kr/dataList/OA-12928/F/1/datasetView.do#>)

2022년 11월 역별 시간대별 이용인원(1~8호선)

(<http://www.seoulmetro.co.kr/kr/board.do?menuIdx=548&bbsIdx=2215353>)

2023년 11월 역별 시간대별 이용인원(1~8호선)

(<http://www.seoulmetro.co.kr/kr/board.do?menuIdx=548&bbsIdx=2217027>)

서울교통공사_역별 시간대별 승하차인원(24.1~24.12)

(<https://data.seoul.go.kr/dataList/OA-12921/F/1/datasetView.do#>)

서울연구원. (2020). 서울시 교통혼잡도 분석 및 개선방안 연구. 서울연구원 정책보고서

(<https://www.si.re.kr>)

서울시 빅데이터 캠퍼스. 서울시 지하철 이용 데이터

(<https://data.seoul.go.kr>)

서울특별시 교통정보포털(TOPIS)

(<https://topis.seoul.go.kr>)

Kaggle. Public datasets and competitions

(<https://www.kaggle.com>)

Dacon. 지하철 혼잡도 예측 AI 경진대회

(<https://www.dacon.io>)