

지하철 혼잡도 예측 시스템

20210365 이예찬

1. 서론

초고밀도 도시에서의 지하철 혼잡 문제



- * 출퇴근 시간 혼잡은 스트레스, 건강 문제, 사고 위험 유발
- * 교통약자(임산부, 노약자, 휠체어 이용자)에게 큰 장애 요소
- * 사회 전체적으로 생산성 손실, 에너지 낭비, 환경 오염 유발

기존 시스템의 한계



- * 실시간 정보 제공 (O)
- * 미래 예측 기반 추천 (X)



이동 전략 수립 어려움

3. 초기 구현 방법

수집한 데이터

공공데이터



교통

활용사례 등록

URL 복사

목록 이동

서울시 지하철 호선별 역별 시간대별 승하차 인원 정보

교통카드(선후불교통카드 및 1회용 교통카드)를 이용한 지하철 호선별 역별(1~9호선, 서울시 관할 운송기관에 한함) 시간대별 승하차인원을 나타내는 정보입니다.
(* 데이터 적재는 매월 5일 전월 데이터를 갱신합니다.)

공공데이터



교통

활용사례 등록

URL 복사

목록 이동

서울교통공사_지하철혼잡도정보

서울교통공사 1-8호선 30분 단위 평균 혼잡도로 30분간 지나는 열차들의 평균 혼잡도(정원대비 승차인원으로, 승차인과 좌석수가 일치할 경우를 혼잡도 34%로 산정)입니다.(단위: %).
서울교통공사 혼잡도 데이터는 요일구분(평일, 토요일, 일요일), 호선, 역번호, 역명, 상하선구분, 30분단위 별 혼잡도 데이터로 구성되어 있습니다. (2024년부터 분기별 제공됩니다.)

데이터	서울교통공사_지하철혼잡도정보_20250331.xlsx
데이터	서울교통공사_지하철혼잡도정보_20241231.csv
데이터	서울교통공사_지하철혼잡도정보_20240630.csv
데이터	서울교통공사_지하철혼잡도정보_20240331.csv
데이터	서울교통공사_지하철혼잡도정보_20231231.csv
데이터	서울교통공사_역별시간대별혼잡도_20221231.csv

* 지하철 역사별 시간대별 이용량은 개찰구를 통과하여 역사 내로 들어간 사람과 개찰구를 통과하여 역사 밖으로 나온 사람의 수를 측정

* 혼잡도 지수는 (승차인원 - 하차인원) / 역사 수용인원 × 100으로 정의혼잡도는 정량화된 값으로, 34는 좌석이 가득 찬 상태, 100 이상은 입석까지 만원 상태, 120 이상은 매우 혼잡한 상태로 간주

3. 초기 구현 방법

승하차 데이터

	연번	날짜	호선	역명	구분	06시 이전	06 시-07 시	07 시-08 시	08 시-09 시	09 시-10 시	...	17 시-18 시	18 시-19 시	19 시-20 시	20 시-21 시	21 시-22 시	22 시-23 시	23 시-24 시	24시 이후	label	요일 구분
0	185	2024-01-01	3호선	오금	승차	77	77	82	113	132	...	115	107	80	87	32	32	3	0	0	공휴일
1	186	2024-01-01	3호선	오금	하차	1	57	44	53	66	...	172	162	147	143	122	172	92	23	0	공휴일
2	729	2024-01-02	3호선	오금	승차	189	351	1261	1397	605	...	387	498	185	125	104	61	26	1	0	평일
3	730	2024-01-02	3호선	오금	하차	2	106	257	555	226	...	498	1041	719	400	334	358	160	73	0	평일
4	1273	2024-01-03	3호선	오금	승차	184	353	1288	1451	603	...	428	552	198	124	100	90	91	2	0	평일

3. 초기 구현 방법

혼잡도 데이터

요구 구분	요일	호선	출발 역	상하 구분	역 번호	6시 이전	6시00분	6시30분	7시00분	7시30분	...	18시30분	19시00분	19시30분	20시00분	20시30분	21시00분	21시30분	22시
0	요일	3	가락 시장	상선	2	3.878754	5.192782	3.019956	2.973477	3.292418	...	5.821732	4.393845	4.802720	5.291656	5.578141	4.924215	4.772256	4.1
1	요일	3	가락 시장	하선	2	0.000000	2.988832	1.765411	1.608685	1.581488	...	7.126221	5.632075	6.000523	5.339213	7.881546	7.018369	5.706282	6.7
2	요일	3	경복 궁	상선	25	5.265958	4.550835	3.674143	4.789848	5.230108	...	32.364166	26.247018	25.209074	23.850857	32.008344	29.229188	24.384851	25.1
3	요일	3	경복 궁	하선	25	11.653151	13.434248	12.964530	12.672494	18.792132	...	24.835406	23.276872	17.771478	19.290102	15.335216	15.320907	15.309518	14.2
4	요일	3	경찰 병원	상선	1	2.782725	3.431710	1.995971	1.948979	2.710533	...	3.031091	2.168940	2.845082	3.112701	3.570654	3.109177	2.623802	2.2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
199	평균	3	총무 구	하선	21	21.817595	34.840478	35.826919	54.423498	62.326952	...	51.075878	33.471874	25.285470	21.553269	21.455135	24.712288	25.208805	27.9

3. 초기 구현 방법

서울교통공사 혼잡도 데이터는 요일구분(평일, 토요일, 일요일), 호선, 역번호, 역명, 상하선구분, 30분단위 별 혼잡도 데이터로 구성되어 있습니다. (2024년부터 분기별 제공됩니다.)

- * 2022년과 2023년은 연간 데이터가 존재하고 2024년은 분기별 데이터가 존재, 따라서 연간데이터를 분기별로 확장시키는 작업(방법 1)이나 분기별 데이터를 연간 데이터로 압축하는 작업(방법 2)이 필요
- * 방법 2는 데이터 손실이 많이 발생하므로 방법 1 선택

3. 초기 구현 방법

$$\begin{aligned} &\text{분기별 혼잡도 차이} \\ &= \text{연간 혼잡도 차이} + \alpha \times (\text{분기별 승하차 인원} - \text{연평균 승하차 인원}) \end{aligned}$$

혼잡도 차이 = 현재역 혼잡도 - 전역 혼잡도
승하차 인원 = 승차 인원 - 하차 인원

- * 승차인원에서 하차인원을 뺀 값이 연평균보다 크면 혼잡도가 연평균보다 높아지고, 반대로 그 값이 작으면 혼잡도가 연평균보다 낮아질 것이라고 가정
- * 위 가정을 바탕으로, 혼잡도 변화가 승하차 인원 변화에 선형적으로 비례한다고 보고, 선형 회귀 (최소제곱법)를 통해 α 값을 추정
- * 2024년의 분기별 혼잡도를 통해 α 계산, α 를 통해 2022, 2023년의 분기별 혼잡도 도출

3. 초기 구현 방법

R² 값 결과

단일 α

```
calculate_alpha_least_squares(df2024_comparison, cong_2024_1_diff, cong_2024_2_diff, cong_2024_3_diff, cong_2024_4_diff)
```

```
2.0215136213146077e-05
```

시간대별 α

```
alphas = calculate_alpha_per_time(df2024_comparison, cong_2024_1, cong_2024_2, cong_2024_3, cong_2024_4)  
sum(alphas.values()) / len(alphas.values())
```

```
4.2364363633596585e-05
```

역사별 α

```
r2s = calculate_r_squared_per_time(alpha_dict=alphas, df_comparison=df2024_comparison, cong_1_diff=cong_2024_1,  
                                   cong_2_diff=cong_2024_2, cong_3_diff=cong_2024_3, cong_4_diff=cong_2024_4  
                                   )
```

```
sum(r2s.values()) / len(r2s.values())
```

```
-3.086574951650471
```

3. 초기 구현 방법

결론

- * 예상과 달리 극도로 낮은 결정계수 및 음의 결정계수가 도출
- * 승하차량과 혼잡도 간의 선형 관계 가정이 성립하지 않음을 명시
- * 지하철 혼잡도와 승하차량 간의 관계가 가정한 선형 모델로는 설명될 수 없는 복잡한 비선형적 특성을 가지고 있거나, 아예 다른 요인들에 의해 결정될 가능성이 제기

4. 데이터셋 분포 확인

제목	지하철 혼잡도 데이터 관련 문의드립니다.		
분류	문의		
작성일	2025-05-20 16:37	처리기한	2025-05-28
처리단계	답변완료	접수부서	안전계획처

지하철 혼잡도 데이터를 이용하여 데이터 분석을 진행 중인 대학교 3학년 학생입니다.
자료실에 있는 지하철 혼잡도의 분기별 및 연간 데이터에서 혼잡도를 측정한 정확한 시점이 궁금하여 연락드렸습니다.

특정 역에서의 혼잡도로 적힌 수치가 역에서 승하차를 마친 후 다음 역으로 이동하는 과정에서의 혼잡도가 맞는지 알고 싶습니다.
또한, 혼잡도를 어떤 방식으로 측정했는지를 알려주시면 감사하겠습니다.

첨부파일

처리결과			
처리부서	안전계획처	처리자	홍보석
처리완료일	2025-05-22 08:58	처리자메일	boseokdowk@seoulmetro.co.kr

안녕하십니까? 귀하께서 고객님의소리를 통해 신청하신 민원에 대한 검토 결과를 다음과 같이 알려드립니다.
귀하의 민원내용은 “지하철 혼잡도 측정 시점 및 혼잡도 측정 방식”에 관한 것으로 이해되며, 귀하의 질의사항에 대해 검토한 의견은 다음과 같습니다.

가. 공사 홈페이지 지하철 혼잡도(알림마당→혼잡도→열차혼잡도) 데이터의 측정기간은 다음과 같습니다.

1) 2024년 3분기 : '24.09.23.(월) ~ 09.29.(일) / 7일 간

2) 2024년 4분기 : '24.11.01.(금) ~ 11.30.(토) / 30일 간

3) 2025년 1분기 : '25.03.17.(월) ~ 03.23.(일) / 7일 간

나. 특정 역의 혼잡도 데이터는 승하차 후 다음 역으로 이동하는 열차의 혼잡도 값입니다.
예시) 2호선 방배역 외선 143.0퍼센트 : 방배역 승하차 후 서초역으로 이동하는 열차의 혼잡도

다. 혼잡도 측정방식은 다음과 같습니다.

1) 교통카드 승하차 내역을 기반으로 승객의 출발역~도착역 최적 경로 산정

2) 최적 경로를 기반으로 승객의 탑승열차 추정에 따른 열차 탑승인원 산정

3) 혼잡도 정의에 의한 열차 혼잡도 산출

귀하의 질문에 만족스러운 답변이 되었기를 바라며, 답변 내용에 대한 추가 설명이 필요한 경우 서울교통공사 안전계획처 영채영 대리(☎02-6311-2063)에 게 연락주시면 친절히 안내해 드리겠습니다. 감사합니다.

<

02-6311-2063

5월 22일 목요일

오후 5:36


발신전화, 7분 22초

4. 데이터셋 분포 확인

* 연간 데이터가 아닌 특정 일주일에 대한 데이터

혼잡도 데이터

2022년 역별 시간대별 혼잡도
2023년 역별 시간대별 혼잡도
2024년 1분기 역별 시간대별 혼잡도
2024년 2분기 역별 시간대별 혼잡도
2024년 3분기 역별 시간대별 혼잡도
2024년 4분기 역별 시간대별 혼잡도



실제 파악한 혼잡도 데이터

2022.11.07 ~ 2022.11.13 역별 시간대별 평균 혼잡도
2023.11.06 ~ 2023.11.12 역별 시간대별 평균 혼잡도
2024.03.18 ~ 2024.03.24 역별 시간대별 평균 혼잡도
2024.06.17 ~ 2024.06.23 역별 시간대별 평균 혼잡도
2024.09.23 ~ 2024.09.29 역별 시간대별 평균 혼잡도
2024.11.01 ~ 2024.11.30 역별 시간대별 평균 혼잡도

5. 보안한 모델 학습 방법

문제 해결

- * 이중 모델링 전략으로 시스템의 복잡성을 관리
- * 모델 1 : 과거 승하차 데이터 → 미래 승하차 예측
일별, 시간대별로 데이터가 존재하여, 이상치 파악 및 정확한 예측 가능
- * 모델 2 : 승하차 데이터 → 혼잡도 예측
혼잡도를 측정한 기간을 정확히 알고 있으므로 승하차 데이터를 이용하여 혼잡도를 예측

과거 승하차 데이터 → 미래 승하차량 예측 → 미래 혼잡도 예측 가능

6. 전처리

혼잡도 데이터셋

	요일 구분	호 선	출발 역	상하 구분	6시00 분	6시30 분	7시00 분	7시30 분	8시00 분	8시30 분	...	19시 30분	20시 00분	20시 30분	21시 00분	21시 30분	22시 00분	22시 30분	23시 00분	23시 30분	label
0	평일	7	온수	상선	33.6	51.7	63.9	87.1	105.6	81.8	...	15.1	14.6	14.9	11.1	13.7	14.3	11.0	13.8	7.2	0
1	토요일	7	온수	상선	20.1	17.2	17.6	19.0	36.6	38.2	...	12.0	14.9	13.1	10.8	11.3	16.9	14.6	13.5	4.9	0
2	일요일	7	온수	상선	10.2	10.5	9.4	10.7	19.7	25.1	...	13.0	15.3	11.8	10.9	10.3	12.6	10.5	7.4	3.2	0
3	평일	7	온수	하선	15.8	8.4	14.2	24.7	39.4	15.6	...	54.8	35.4	25.9	40.3	26.8	34.7	34.9	42.0	19.1	0
4	토요일	7	온수	하선	14.3	15.0	8.3	15.2	10.2	12.5	...	33.1	21.3	23.7	35.2	21.7	28.8	25.5	28.2	19.7	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
247	토요일	7	장암	상선	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	41
248	일요일	7	장암	상선	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	41
249	평일	7	장암	하선	4.8	7.6	10.9	16.2	10.3	5.5	...	0.6	0.5	0.5	0.4	0.5	0.6	0.3	0.2	0.1	41
250	토요일	7	장암	하선	0.7	1.8	1.8	2.4	3.3	2.2	...	0.7	0.8	1.2	0.3	0.6	0.2	0.5	0.4	0.1	41
251	일요일	7	장암	하선	0.3	0.6	0.6	2.0	1.1	1.0	...	1.0	0.5	0.7	0.7	0.6	0.5	0.2	0.2	0.0	41

→ 1시간 단위로 변경

원핫 인코딩

6. 전처리

승하차 데이터셋

	날짜	호선	역명	구분	06 ~ 07	07 ~ 08	08 ~ 09	09 ~ 10	10 ~ 11	11 ~ 12	...	17 ~ 18	18 ~ 19	19 ~ 20	20 ~ 21	21 ~ 22	22 ~ 23	23 ~ 24	합계	요일구분	label
0	2024-11-01	7호선	온수	승차	820	1978	2297	889	439	432	...	657	570	265	183	167	122	101	11914	평일	0
1	2024-11-01	7호선	온수	하차	161	489	756	527	345	291	...	884	1601	1105	716	503	506	347	10761	평일	0
2	2024-11-01	7호선	천왕	승차	814	2349	2439	1263	650	506	...	754	639	308	220	163	124	56	13219	평일	1
3	2024-11-01	7호선	천왕	하차	268	421	863	282	265	377	...	1278	1933	1401	786	637	607	465	12747	평일	1
4	2024-11-01	7호선	광명사거리	승차	1282	3306	3481	1599	991	983	...	1574	1349	878	467	437	384	188	23104	평일	2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2515	2024-11-30	7호선	수락산	하차	163	186	336	526	655	600	...	907	860	592	645	608	558	376	10587	토요일	39
2516	2024-11-30	7호선	도봉산	승차	229	398	604	554	524	552	...	402	253	138	123	103	76	28	6843	토요일	40
2517	2024-11-30	7호선	도봉산	하차	126	175	344	581	555	510	...	676	615	500	475	541	510	416	8910	토요일	40
2518	2024-11-30	7호선	장암	승차	39	92	162	143	126	99	...	121	91	64	51	25	25	9	1900	토요일	41
2519	2024-11-30	7호선	장암	하차	38	48	57	109	136	98	...	106	59	45	55	35	42	21	1330	토요일	41

→ 평일, 토요일, 일요일로 구분

→ 혼잡도 데이터셋과 병합

6. 전처리

1. 원핫 인코딩

	label	구분_상선	구분_하선	요일_공휴일	요일_토요일	요일_평일	시간대_06~07	시간대_07~08	시간대_08~09	시간대_09~10	...	시간대_16~17	시간대_17~18	시간대_18~19	시간대_19~20	시간대_20~21	시간대_21~22	시간대_22~23	시간대_23~24	승차	하차
0	0	True	False	True	False	False	True	False	False	False	...	False	False	False	False	False	False	False	False	118.0000000000	69.0000000000
1	0	False	True	True	False	False	True	False	False	False	...	False	False	False	False	False	False	False	False	118.0000000000	69.0000000000
2	0	True	False	False	False	True	True	False	False	False	...	False	False	False	False	False	False	False	False	830.3333333333	147.8095238095
3	0	False	True	False	False	True	True	False	False	False	...	False	False	False	False	False	False	False	False	830.3333333333	147.8095238095
4	0	True	False	False	True	False	True	False	False	False	...	False	False	False	False	False	False	False	False	224.0000000000	86.2000000000
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
4531	41	False	True	True	False	False	False	False	False	False	...	False	False	False	False	False	False	False	True	6.7500000000	13.2500000000
4532	41	True	False	False	False	True	False	False	False	False	...	False	False	False	False	False	False	False	True	9.8571428571	25.2380952381
4533	41	False	True	False	False	True	False	False	False	False	...	False	False	False	False	False	False	False	True	9.8571428571	25.2380952381
4534	41	True	False	False	True	False	False	False	False	False	...	False	False	False	False	False	False	False	True	9.4000000000	23.4000000000
4535	41	False	True	False	True	False	False	False	False	False	...	False	False	False	False	False	False	False	True	9.4000000000	23.4000000000

4536 rows × 26 columns

* 시간대를 독립적으로 처리

* 피처 수 증가, 시계열성 무시

6. 전처리

2. 레이블 인코딩

	label	구분_상선	구분_하선	요일구분_공휴일	요일구분_토요일	요일구분_평일	시간대_label	승차	하차
0	0	True	False	False	False	True	0	830.3333333333	147.8095238095
1	0	False	True	False	False	True	0	830.3333333333	147.8095238095
2	0	True	False	False	True	False	0	224.0000000000	86.2000000000
3	0	False	True	False	True	False	0	224.0000000000	86.2000000000
4	0	True	False	True	False	False	0	118.0000000000	69.0000000000
...	...	...	...	...	...	...	...	...	...
4531	41	False	True	False	False	True	17	9.8571428571	25.2380952381
4532	41	True	False	False	True	False	17	9.4000000000	23.4000000000
4533	41	False	True	False	True	False	17	9.4000000000	23.4000000000
4534	41	True	False	True	False	False	17	6.7500000000	13.2500000000
4535	41	False	True	True	False	False	17	6.7500000000	13.2500000000

4536 rows × 9 columns

* 시간대를 정수값으로 변환하여 시계열
순서 반영

* 출근 시간대와 퇴근 시간대의 혼잡도가
높은데 단순한 선형 처리가 적절한지 의문

6. 전처리

3. 주기 인코딩

	label	구분_상선	구분_하선	요일구분_공휴일	요일구분_토요일	요일구분_평일	시간대_label	승차	하차	시간대_sine	시간대_cosine
0	0	True	False	False	False	True	0	830.3333333333	147.8095238095	0.7660444431	0.6427876097
1	0	False	True	False	False	True	0	830.3333333333	147.8095238095	0.7660444431	0.6427876097
2	0	True	False	False	True	False	0	224.0000000000	86.2000000000	0.7660444431	0.6427876097
3	0	False	True	False	True	False	0	224.0000000000	86.2000000000	0.7660444431	0.6427876097
4	0	True	False	True	False	False	0	118.0000000000	69.0000000000	0.7660444431	0.6427876097
...	...	...	...	...	...	...	...	...	...	...	...
4531	41	False	True	False	False	True	17	9.8571428571	25.2380952381	0.5000000000	0.8660254038
4532	41	True	False	False	True	False	17	9.4000000000	23.4000000000	0.5000000000	0.8660254038
4533	41	False	True	False	True	False	17	9.4000000000	23.4000000000	0.5000000000	0.8660254038
4534	41	True	False	True	False	False	17	6.7500000000	13.2500000000	0.5000000000	0.8660254038
4535	41	False	True	True	False	False	17	6.7500000000	13.2500000000	0.5000000000	0.8660254038

* 시간대 정보를 주기적인 특성으로 간주

* sin, cos 함수를 이용하여 추가 피처를 추출하여, 출퇴근 시간대에 높은 중요도 부여

7. 모델 학습

Linear Regression / XGBRegressor 학습

	Linear Regression	XGBRegressor
MSE	271.1944642669	21.2625584333
R2	0.2837534798	0.9438438630
MAE	12.1903591305	3.2730925246

원핫 인코딩

	Linear Regression	XGBRegressor
MSE	286.5656767368	14.6151125403
R2	0.2431568641	0.9614003054
MAE	12.6769245018	2.6832895330

레이블 인코딩

	Linear Regression	XGBRegressor
MSE	279.1123179708	15.0154213633
R2	0.2628417876	0.9603430574
MAE	12.3811228719	2.7278851464

주기 인코딩

* 선형 회귀는 낮은 성능을 보이지만, XGBoost 모델은 높은 성능을 보여줌

* 원핫 인코딩에 비해 레이블 인코딩과 주기 인코딩의 성능이 더 좋으며 둘의 차이는 미미

7. 모델 학습

Ridge_regression / XGBRegressor 하이퍼파라미터 튜닝

	Ridge	XGBoost
MSE	237.8509502053	12.2906888564
R2	0.3718163980	0.9675392964
MAE	11.6448240298	2.4850465981

원핫 인코딩

	Ridge	XGBoost
MSE	286.5899109337	15.5515463421
R2	0.2430928597	0.9589271080
MAE	12.6847576367	2.6805583749

레이블 인코딩

	Ridge	XGBoost
MSE	286.5899109337	9.9463345396
R2	0.2430928597	0.9737309258
MAE	12.6847576367	2.2229235854

주기 인코딩

- * Ridge 회귀에서 성능 향상을 보였지만, 여전히 낮은 성능
- * 원핫 인코딩과 주기 인코딩에서 성능 향상, 레이블 인코딩은 성능이 오히려 약간 감소
- * XGBoost 주기 인코딩의 Test R^2 값이 0.973으로 가장 높은 수치를 기록

8. 추가 검증

실제 파악한 혼잡도 데이터

2022.11.07 ~ 2022.11.13 역별 시간대별 평균 혼잡도
2023.11.06 ~ 2023.11.12 역별 시간대별 평균 혼잡도
2024.03.18 ~ 2024.03.24 역별 시간대별 평균 혼잡도
2024.06.17 ~ 2024.06.23 역별 시간대별 평균 혼잡도
2024.09.23 ~ 2024.09.29 역별 시간대별 평균 혼잡도
2024.11.01 ~ 2024.11.30 역별 시간대별 평균 혼잡도

	2024년 3월	2024년 6월	2024년 9월
MSE	10.8983504287	13.9196966512	11.9066123602
R2	0.9725923301	0.9602323310	0.9698412840
MAE	2.3413370109	2.6498631671	2.2947694578

9. 결론

- * 서울교통공사에서 제공하는 2022년 11월, 2023년 11월, 2024년 분기별 혼잡도 데이터를 기반으로 XGBoost 회귀 모델을 최적화하는 데 성공
- * 현재 모델은 7호선 구간의 데이터에만 국한해서 학습 수행, 따라서 다른 노선으로의 일반화 가능성 검토 필요
- * 향후 과거 승하차 데이터 -> 미래 승하차 예측 모델 구현하여 최종적으로 과거 승하차 데이터 -> 미래 혼잡도 예측 모델을 만들 예정